

# Ilustração do Teorema do Limite Central através de simulação de Monte Carlo

Adriano Nascimento da Paixão, 20180015150  
Carlos Alberto Alves de Meneses, 201800032  
Joana D'arc Nunes da Silva, 20180078535

2022-11-20

## 1. Objetivos

- Demonstrar o Teorema do Limite Central por meio de métodos computacionais;
- Gerar números pseudo-aleatórios para amostras de diferentes tamanhos;
- Utilizar a simulação de Monte Carlo para demonstrar a convergência em distribuição.

## 2. Objetivo principal

- Ilustrar o Teorema do Limite Central através de simulação de Monte Carlo, considerando diferentes tamanhos de amostras e diferentes distribuições de probabilidade.

## 3. Introdução

A ideia de convergência em distribuição ou do que chamamos a distribuição limite é de fundamental importância em Estatística. A motivação para tal estudo é a de que muitas vezes a distribuição de uma determinada variável aleatória de interesse pode ser difícil de ser encontrada ou de se trabalhar. Porém, supondo que a informação de que dispomos é suficientemente grande, a distribuição de interesse pode muitas vezes ser aproximada por uma distribuição limite conhecida; por exemplo, uma distribuição normal-padrão. Essa informação disponível é na maioria das vezes traduzida pelo número total de observações (amostras) sobre o experimento. Uma fração significativa dos resultados é consequência do chamado *Teorema Central do Limite*. O teorema central do limite pode ser visto como uma informação adicional àquela que é dada pela lei dos grandes números, na seguinte forma. Para uma sequência  $(X_n)$  de variáveis aleatórias i.i.d. e integráveis de esperança  $\mu$ , a lei forte dos grandes números diz que a média amostral  $\bar{X}_n$  converge quase certamente para  $\mu$ . Sendo assim, a distribuição de  $\bar{X}_n$  deve convergir para uma distribuição concentrada em  $\mu$ . O teorema central do limite traz uma informação adicional. Ele afirma que, se a variância  $\sigma^2$  da distribuição comum for finita, a convergência dá-se de tal forma que a distribuição de  $\sqrt{n}(\bar{X}_n - \mu)$  pode ser cada vez mais bem aproximada pela distribuição  $N(0, \sigma^2)$ . Equivalentemente, a distribuição de  $\bar{X}_n$  torna-se cada vez mais próxima da distribuição  $N(\mu, \frac{\sigma^2}{n})$ . Dessa forma, o teorema central do limite dá uma descrição sobre como a distribuição de  $\bar{X}_n$  converge para a distribuição concentrada em  $\mu$ , (VASCONCELLOS, 2021).

## 3. Resultados Fundamentais

**Definição 3.1.** Seja  $(X_n)$  uma sequência de variáveis aleatórias reais e seja  $F_n$  a sua função de distribuição de  $(X_n)$ , para cada  $n$ . Suponha que exista função de distribuição  $F$  tal que  $F_n(x) \rightarrow F(x)$  para todo  $x \in \mathbb{R}$  que é ponto de continuidade de  $F$ . Neste caso, dizemos que a sequência  $(X_n)$  converge em distribuição para  $F$ .

**Notação:** " $X_n \rightarrow^D F$ "

**Teorema 3.1.** [*Teorema Central do Limite clássico*] Seja  $(X_n)$  uma sequência de variáveis aleatórias i.i.d. com  $E[X_1^2] < \infty$ . Suponha  $\sigma^2 = \text{Var}(X_1) \neq 0$  e seja  $\mu = E(X_1)$ . Seja  $S_n = X_1 + X_2 + \dots + X_n$ . Tem-se

$$T_n = \frac{S_n - n\mu}{\sigma\sqrt{n}} \rightarrow^D N(0, 1)$$

Considere a média amostral  $\bar{X}_n = \frac{S_n}{n}$ . Observe que uma forma equivalente de se enunciar o Teorema 3.1 é

$$\sqrt{n}(\bar{X}_n - \mu) \rightarrow^D N(0, \sigma^2)$$

, que é muito usada na Inferência Estatística, pois descreve diretamente o comportamento da média amostral como estimador de  $\mu$ . Em outras palavras, podemos trabalhar diretamente com a distribuição normal ao invés de trabalharmos com uma distribuição mais complicada ao termos conhecimento que a mesma converge para uma  $N(\mu, \frac{\sigma^2}{n})$ .

**Exemplo 3.1.** [Aproximação da binomial pela normal] Seja  $(x_n)$  uma seqüência de variáveis aleatórias i.i.d. com distribuição comum Bernoulli de parâmetro  $p$ . Nesse caso, sabemos que  $S_n = X_1 + \dots + X_n$  tem distribuição binomial com parâmetros  $n$  e  $p$ . Ainda pelo teorema 3.1,  $\frac{(S_n - np)}{\sqrt{np(1-p)}} \rightarrow^D N(0, 1)$ . De outra forma, isso significa que, para valores grandes de  $n$ , a distribuição  $N(np, np(1-p))$  fornece uma boa aproximação para a distribuição  $Binomial(n, p)$ . Suponha, por exemplo, que queremos a probabilidade de que, em  $n = 400$  lançamentos independentes de uma moeda honesta, o número total de caras não ultrapasse 220. O valor procurado é

$$\frac{1}{2^{400}} \sum_{k=0}^{220} \binom{400}{k}$$

cujas obtenção numérica é bastante trabalhosa. O resultado arredondado para três casas decimais é 0,980. Uma aproximação pode ser obtida facilmente usando aqui a distribuição  $N(200, 100)$ . Nesse caso calculamos  $\phi(220 - 200/10) = \phi(2)$ , onde  $\phi$  é a função de distribuição para a distribuição  $N(0, 1)$ . Essa última aproximação arredondada para três casas decimais é 0,977, que representa uma redução de apenas 0,3% do valor verdadeiro.

## [1] 0.9772499

## 4. Simulações

### 4.1. Apresentando Aleatoriedade

Uma parte crítica da modelagem de simulações é o uso de processos aleatórios. Um *processo aleatório* é aquele que gera um resultado diferente de acordo com algumas regras cada vez que é executado. Nesse trabalho, iremos gerar números pseudo-aleatórios para gerarem amostras que serão utilizadas nas simulações para demonstrar o Teorema Central do Limite (TCL), usando o método de Monte Carlo.

### 4.2 Reproduzindo Aleatoriedade

Como queremos obter os mesmos números aleatórios exatos, iremos inicialmente definir uma *semente aleatória*.

### 4.3. Replicação

Para usar os métodos de Monte Carlo, precisaremos replicar algum processo aleatório muitas vezes. Existem duas maneiras de fazer isso: com *replicate ()* ou com *for ()*, loops. Nesse trabalho utilizaremos loop's. A simulação de Monte Carlo inicia-se com a geração de números pseudo-aleatórios. Números pseudo-aleatórios constituem uma seqüência de valores que, apesar de serem gerados de maneira determinística, possuem características semelhantes a variáveis aleatórias independentes  $U(0, 1)$ .

Geradores de números aleatórios são usados em simulação estocástica, amostragem, análise numérica, teste de programas, jogos de azar, tomada de decisões, etc.

A distribuição  $U(0,1)$  fornece a representação probabilística básica da aleatoriedade em um computador e os geradores de todas as outras distribuições requerem que uma sequência de variáveis aleatórias  $U(0,1)$  seja simulada.

#### 4.3.1 Exemplo: Geração de números pseudo-aleatórios para uma distribuição exponencial.

```
#Programa R demonstrando a geração de
#n realizações de variáveis aleatórias
#exponenciais com parâmetro lamb,
#utilizamos a função *runif()*
#para gerarmos números aleatórios
#uniformes
```

```
rexpon <- function(n, lamb=1/3)
{
  u <- runif(n, 0, 1) # gera vetor u
  #(U(0,1))
  x <- -log(u) / lamb # gera vetor x
  #com distrib. exp.
  return(x) # retorna o vetor x
}
```

```
# exemplo
```

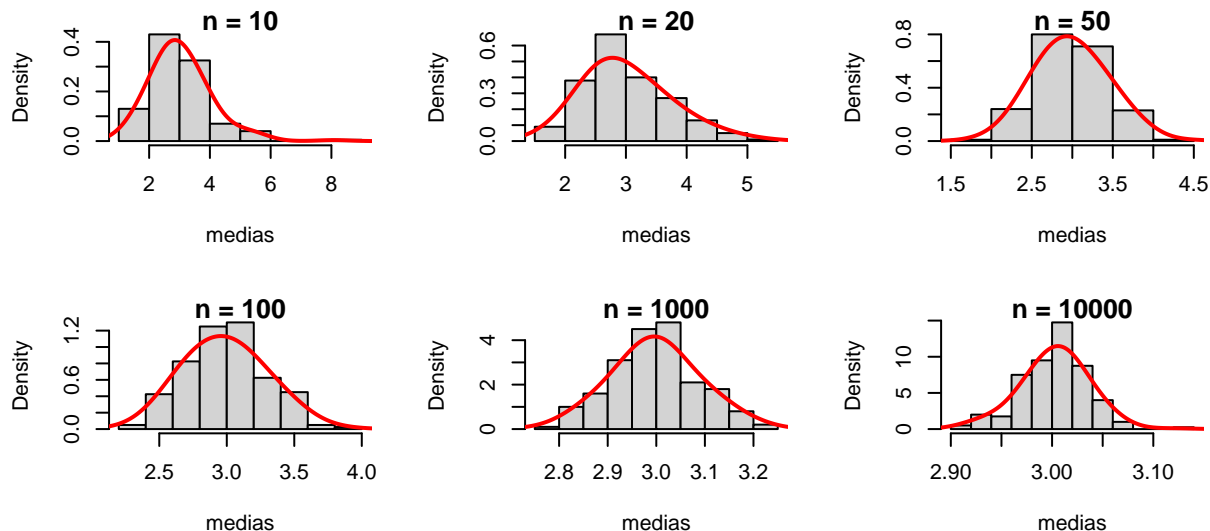
```
rexpon(20, 1/3)
```

```
## [1] 0.32711113 3.97832343 2.96558525 1.67137652 0.28884625 4.80319026
## [7] 0.32145407 0.17074212 1.24292219 1.39032819 8.35222230 4.74000762
## [13] 5.20233873 1.12616319 2.87052799 0.78471220 2.09327795 0.99545153
## [19] 0.02438052 2.90247436
```

#### 4.3.2 TCL:Exemplo utilizando a distribuição exponencial.

A densidade de uma exponencial com parâmetros  $\lambda$  é dada pela expressão:  $f(x) = \lambda e^{-\lambda x}$ ,  $x \geq 0$ .

Gerando dados por simulação a partir de uma exponencial com  $\lambda = \frac{1}{3}$ , para cada um dos seguintes tamanhos  $n$  de amostras: 10,20,50,100,1000 e 10000.



#### Resultados

- Obtivemos 200 valores da média amostral;

- Utilizamos esses 200 valores para construir um histograma;

Os oito histogramas nos mostram que, à medida que o tamanho  $n$  da amostra cresce, a forma do histograma se aproxima cada vez mais de uma curva normal, comprovando o *Teorema Central do Limite*.

## 5. Análise Exploratória


### 5.1 Teste da Normalidade

Utilizaremos o teste de Shapiro-Wilk para verificarmos a normalidade dos dados.

```
##
## Shapiro-Wilk normality test
##
## data:  medias
## W = 0.98723, p-value = 0.06896
```

### 5.2 Plotando o Gráfico

#### Gráfico QQ (QQ Plot)



Análise:  $p\text{-value} = 0,2379$ , indica uma probabilidade de que essa variável veio de uma distribuição normal o que é comprovada pela análise gráfica.


### 5.3 Estatística descritiva com o pacote *DescTools*

O pacote *DescTools* foi desenvolvido com o objetivo de fornecer uma análise descritiva de forma muito rápida e completa, permitindo ao analista ganhar tempo nessa tarefa. A principal função no pacote é *Desc* que foi concebida para descrever as variáveis de acordo com sua natureza, produzindo medidas descritivas e uma representação gráfica adequada.

```
## -----
## n = 10
##
##      length      n      NAs  unique      Os      mean      meanCI '
##         200       200       0      = n       0  3.104841  2.965081
##           100.0%    0.0%           0.0%           3.244602
```


```
##
##      .05      .10      .25    median      .75      .90      .95
##  1.739444  1.973759  2.387068  2.931093  3.729969  4.488185  4.981897
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  5.252649  1.002312  0.322822  0.881572  1.342901  0.709943  0.221763
##
## lowest : 1.151241, 1.283738, 1.364432, 1.444553, 1.586859
## highest: 5.538531, 5.539843, 5.735027, 6.165951, 6.403891
##
## ' 95%-CI (classic)
```

**n = 10**




```
## -----
## n = 20
##
##      length      n      NAs      unique      Os      mean      meanCI'
##      200        200        0      = n        0  3.093052  2.994691
##      100.0%      0.0%                0.0%                3.191413
##
##      .05      .10      .25    median      .75      .90      .95
##  2.037961  2.262536  2.558814  3.053585  3.577027  3.985371  4.321258
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  3.906783  0.705410  0.228063  0.749570  1.018214  0.327175 -0.049957
##
## lowest : 1.546148, 1.589663, 1.669446, 1.768528, 1.827099
## highest: 4.542226, 4.547678, 4.885943, 4.979931, 5.452931
##
## ' 95%-CI (classic)
```

n = 20




```
## -----
## n = 50
##
##      length      n      NAs    unique      Os      mean      meanCI'
##      200        200        0      = n        0  2.968914  2.910151
##      100.0%      0.0%                0.0%                3.027678
##
##      .05      .10      .25    median      .75      .90      .95
##  2.300790  2.426785  2.701796  2.940700  3.240780  3.515142  3.717048
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  2.284106  0.421433  0.141949  0.397262  0.538984  0.242500 -0.094424
##
## lowest : 1.982594, 2.109037, 2.110487, 2.136096, 2.164974
## highest: 3.802139, 3.821412, 4.006606, 4.107342, 4.2667
##
## ' 95%-CI (classic)
```

n = 50



```
## -----
## n = 100
##
##      length      n      NAs    unique      0s      mean      meanCI'
##      200        200        0      = n        0  3.024341  2.985948
##      100.0%      0.0%                0.0%                3.062734
##
##      .05      .10      .25    median      .75      .90      .95
##  2.572692  2.679513  2.840114  3.024602  3.230157  3.377249  3.458068
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  1.467421  0.275338  0.091041  0.291609  0.390043  0.003101 -0.302847
##
## lowest : 2.272232, 2.394857, 2.403702, 2.445071, 2.45261
## highest: 3.609173, 3.629923, 3.677729, 3.6784, 3.739654
##
## ' 95%-CI (classic)
```


n = 100



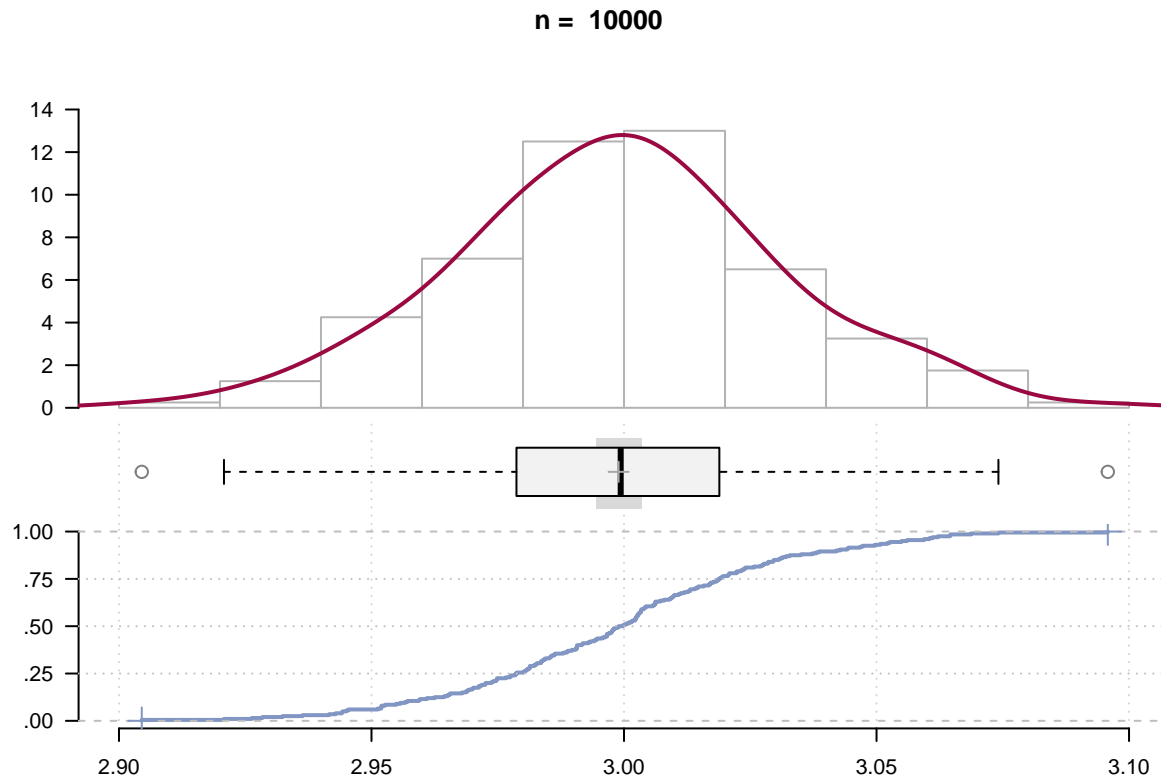
```
## -----
## n = 1000
##
##      length      n      NAs    unique      Os      mean      meanCI '
##      200        200        0      = n        0  3.007109  2.992902
##      100.0%      0.0%
##
##      .05      .10      .25    median      .75      .90      .95
##  2.839520  2.870014  2.948589  3.005270  3.070973  3.130994  3.173253
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  0.573530  0.101891  0.033883  0.093158  0.122385  0.109665  0.217103
##
## lowest : 2.761571, 2.76506, 2.774486, 2.798427, 2.799289
## highest: 3.208918, 3.218866, 3.246766, 3.307578, 3.335101
##
## ' 95%-CI (classic)
```



n = 1000



```
## -----
## n = 10000
##
##      length      n      NAs    unique      Os      mean      meanCI '
##        200        200        0      = n        0  2.998938  2.994461
##          100.0%    0.0%          0.0%          3.003414
##
##      .05      .10      .25    median      .75      .90      .95
##  2.945007  2.957105  2.978736  2.999341  3.018811  3.042107  3.055005
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  0.191285  0.032106  0.010706  0.029401  0.040075  0.035908  0.127774
##
## lowest : 2.904512, 2.920787, 2.92631, 2.92839, 2.932365
## highest: 3.064545, 3.064674, 3.068741, 3.074135, 3.095797
##
## ' 95%-CI (classic)
```



Listamos a seguir as saídas que essa função fornece para o caso de variáveis numéricas

- *length.*, o comprimento do vetor;
- *n.*, o número de observações;
- *NAs.*, o número de observações faltantes;
- *unique.*, o número de observações distintas entre si;
- *0s.*, o número total de valores nulos;
- *mean.*, a média aritmética do vetor;
- *meanSE.*, fornece um intervalo de 95% de confiança para a média, com base no erro padrão da média,;
- *.05, ..., .95* percentil de *x*, iniciando com 5%, 10%, 1\_0. quartil, mediana, etc.;
- *range.*, a amplitude do vetor *x*;
- *sd.*, o desvio-padrão do vetor *x*;
- *vcoef.*, o coeficiente de variação de *x*, definido como ;
- *mad.*, o desvio médio absoluto;
- *IQR.*, a amplitude interquartil, definida por 3^0. quartil - 1^0. quartil;
- *skew.*, o coeficiente de assimetria do vetor *x*;
- *kurt.*, o coeficiente de curtose do vetor *x*;
- *lowest.*, os cinco menores valores do vetor;
- *highest.*, os cinco maiores valores do vetor.

A tabela a seguir expõem as principais métricas estatísticas da distribuição Exponencial geradas:

	Médias	sd	Mediana	Curtose
10	3.104841	1.002312	2.931093	0.2217635
20	3.093052	0.705410	3.053585	-0.0499570
50	2.968914	0.421433	2.940700	-0.0944240
100	3.024341	0.275338	3.024602	-0.3028470
1000	3.007109	0.101891	3.005270	0.2171030
10000	2.998938	0.032106	2.999341	0.1277740

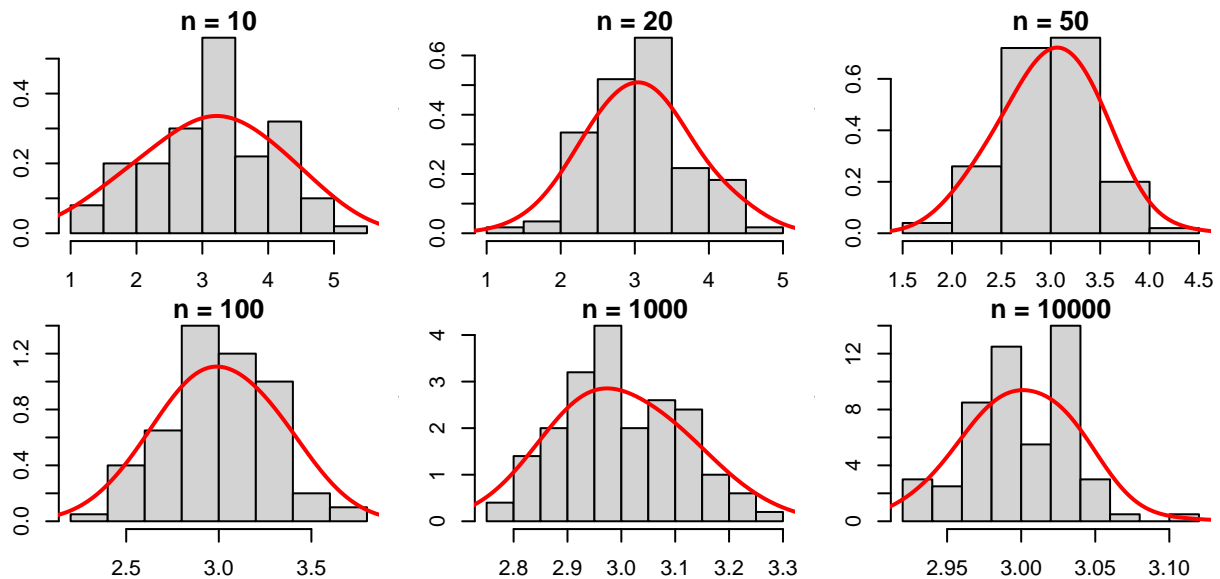
## 6. TCL: Exemplo utilizando a distribuição Uniforme.

**Definição 6.1** Uma variável aleatória  $X$  tomando um número finito de valores com iguais probabilidades diz-se que tem uma *distribuição uniforme*.

A **distribuição uniforme** é a mais simples para variáveis aleatórias contínuas, sendo utilizada para modelar a ocorrência de eventos cuja probabilidade é constante em intervalos de mesma amplitude. Uma variável aleatória  $X$  tem distribuição uniforme no intervalo  $[a, b]$ , denotada por  $X \sim U[a, b]$ , se sua função densidade de probabilidade for dada por:

$$f(x) = \begin{cases} \frac{1}{(b-a)}, & \text{se } a \leq x \leq b \\ 0, & \text{caso contrário.} \end{cases}$$

### 6.2 TCL: Códigos no R para a elaboração dos gráficos com as simulações - Uniforme



Os seis histogramas nos mostram que, à medida que o tamanho  $n$  da amostra cresce, a forma do histograma se aproxima cada vez mais de uma curva normal, comprovando o *Teorema Central do Limite*.


### 6.3 Teste da Normalidade

Utilizaremos o teste de Shapiro-Wilk para verificarmos a normalidade dos dados.

```
##
## Shapiro-Wilk normality test
##
## data: medias.unif
## W = 0.98074, p-value = 0.1518
```

### 6.4 Plotando o Gráfico

## Gráfico QQ (QQ Plot)




Análise: p-value = 0,06896, indica uma probabilidade de que essa variável veio de uma distribuição normal o que é comprovada pela análise gráfica.

### 6.5 Estatística descritiva com o pacote *DescTools*


```
## -----
## n = 10
##
##      length      n      NAs    unique      Os      mean      meanCI '
##      100        100        0      = n      0      3.1431018  2.9611720
##              100.0%    0.0%              0.0%              3.3250317
##
##      .05      .10      .25    median      .75      .90      .95
## 1.7802127 1.9902772 2.6225485 3.0282379 3.7521932 4.3317776 4.6803440
##
##      range      sd      vcoef      mad      IQR      skew      kurt
## 5.3753948 0.9168851 0.2917134 0.7434725 1.1296447 0.2712963 0.2673881
##
## lowest : 0.6387322, 1.1774455, 1.6093421, 1.6838461, 1.7224465
## highest: 4.7940637, 4.8008903, 4.9621393, 5.0824105, 6.0141269
##
## ' 95%-CI (classic)
```

n = 10




```
## -----
## n = 20
##
##      length      n      NAs  unique      Os      mean  meanCI '
##      100      100      0      = n      0  2.977908  2.854809
##      100.0%    0.0%      0.0%
##
##      .05      .10      .25  median      .75      .90      .95
##  2.013011  2.313356  2.554122  2.945761  3.398583  3.705801  3.953854
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  3.402436  0.620392  0.208331  0.637923  0.844461  0.172731  0.308399
##
## lowest : 1.448831, 1.454257, 1.633929, 1.959063, 1.98167
## highest: 4.076656, 4.135136, 4.164316, 4.579352, 4.851267
##
## ' 95%-CI (classic)
```

n = 20




```
## -----
## n = 50
##
##      length      n      NAs  unique      Os      mean      meanCI'
##      100        100        0    = n        0    2.992624    2.900013
##      100.0%      0.0%                0.0%                3.085236
##
##      .05      .10      .25  median      .75      .90      .95
##  2.224880  2.337376  2.710427  3.014753  3.283267  3.617801  3.699617
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  2.259181  0.466740  0.155964  0.434623  0.572841  -0.110976  -0.354584
##
## lowest : 1.793445, 2.015336, 2.018268, 2.143294, 2.189758
## highest: 3.744792, 3.845132, 3.922184, 3.933358, 4.052626
##
## ' 95%-CI (classic)
```

n = 50



```
## -----
## n = 100
##
##      length      n      NAs    unique      Os      mean      meanCI'
##      100      100      0      = n      0      2.982156    2.922829
##      100.0%    0.0%      0.0%
##
##      .05      .10      .25    median      .75      .90      .95
##      2.485097  2.595342  2.796479  2.951018  3.182368  3.390628  3.478418
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##      1.478560  0.298991  0.100260  0.288832  0.385889  -0.005024  -0.407928
##
## lowest : 2.199439, 2.362889, 2.436311, 2.471503, 2.48265
## highest: 3.484247, 3.49299, 3.507794, 3.587643, 3.677999
##
## ' 95%-CI (classic)
```


n = 100



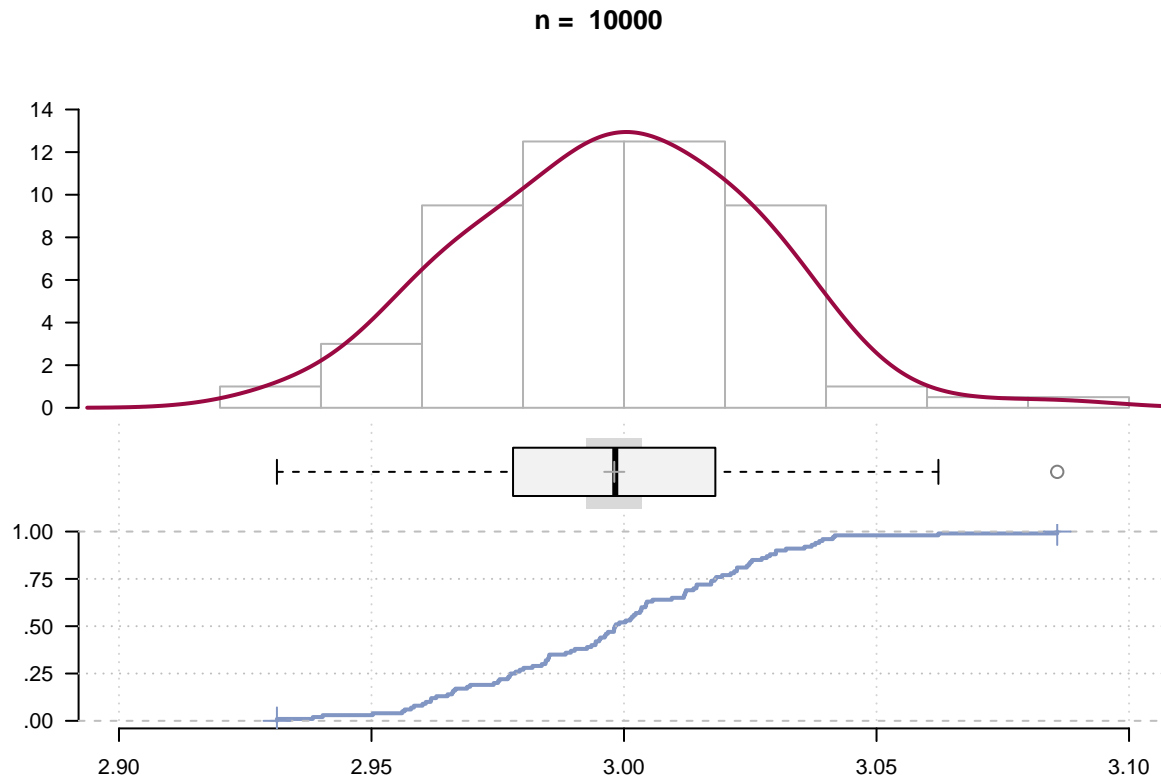
```
## -----
## n = 1000
##
##      length      n      NAs    unique      Os      mean      meanCI'
##      100        100        0      = n        0      2.999369  2.981022
##      100.0%      0.0%                0.0%                3.017717
##
##      .05      .10      .25    median      .75      .90      .95
##      2.847828  2.887817  2.933710  3.003387  3.064653  3.107393  3.122854
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##      0.508969  0.092470  0.030830  0.095758  0.130943  -0.074060  0.045698
##
## lowest : 2.755988, 2.782777, 2.810167, 2.826658, 2.832947
## highest: 3.155937, 3.16011, 3.188469, 3.196786, 3.264957
##
## ' 95%-CI (classic)
```



n = 1000



```
## -----
## n = 10000
##
##      length      n      NAs    unique      Os      mean      meanCI '
##      100        100        0      = n        0  2.998075  2.992542
##      100.0%      0.0%              0.0%              3.003609
##
##      .05      .10      .25    median      .75      .90      .95
##  2.956533  2.961629  2.978281  2.998272  3.018020  3.030278  3.038699
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  0.154504  0.027888  0.009302  0.029424  0.039739  0.084003  0.026326
##
## lowest : 2.931278, 2.938387, 2.940335, 2.950248, 2.95607
## highest: 3.03931, 3.04133, 3.041709, 3.062253, 3.085781
##
## ' 95%-CI (classic)
```



A tabela a seguir expõem as principais métricas estatísticas da distribuição Uniforme geradas:

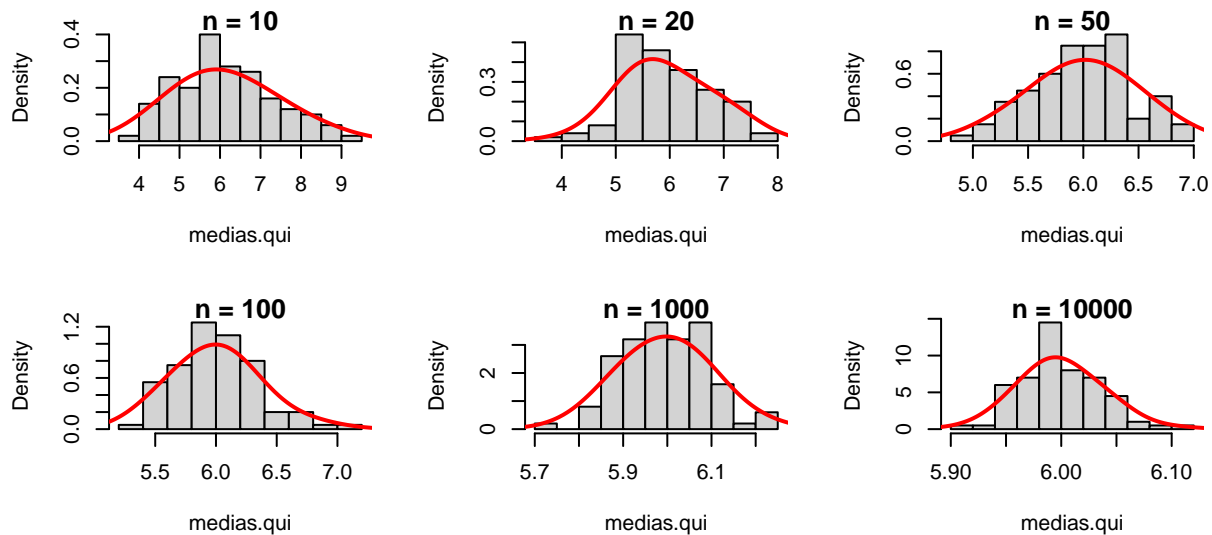
	Médias	sd	Mediana	crtose
10	3.028238	0.9168851	3.028238	0.2673881
20	2.977908	0.6203920	2.945761	0.3083990
50	2.992624	0.4667400	3.014753	-0.3545840
100	2.982156	0.2989910	2.951018	-0.4079280
1000	2.999369	0.0924700	3.003287	0.0456980
10000	2.998075	0.0278880	2.998272	0.0263260

## 7. TCL:Exemplo utilizando a distribuição qui-quadrado.

**Definição 7.1** Uma variável aleatória contínua  $X$  tem *distribuição qui-quadrado* com  $v$  graus de liberdade, denotada por  $X \sim X_v^2$ , se sua função densidade de probabilidade for dada por:

$$f(x) = \begin{cases} \frac{1}{2^{(v/2)}\Gamma(v/2)} x^{(v/2)-1} e^{-x/2} \\ 0, \text{ se } x < 0 \end{cases}$$

### 7.1 TCL: Códigos no R para a elaboração dos gráficos com as simulações - qui-quadrado



Os seis histogramas nos mostram que, à medida que o tamanho  $n$  da amostra cresce, a forma do histograma se aproxima cada vez mais de uma curva normal, comprovando o *Teorema Central do Limite*.

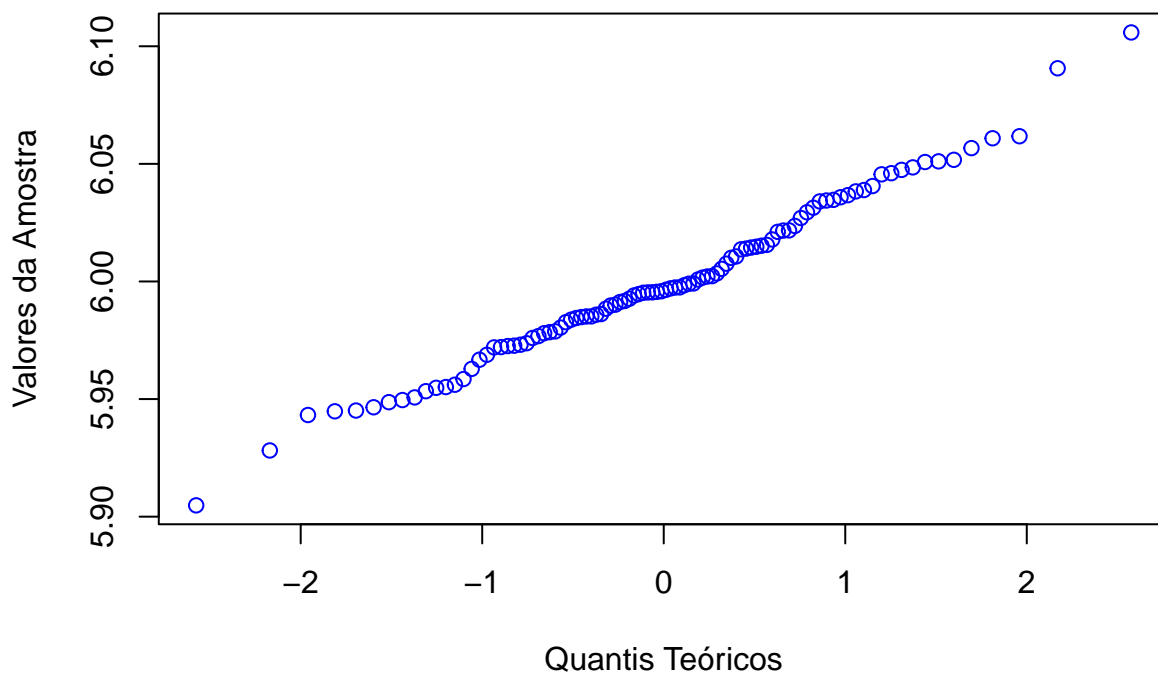
## 7.2 Teste da Normalidade

Utilizaremos o teste de Shapiro-Wilk para verificarmos a normalidade dos dados.

```
##
##  Shapiro-Wilk normality test
##
## data:  medias.qui
## W = 0.98894, p-value = 0.5796
```

## 7.3 Plotando o Gráfico

### Gráfico QQ (QQ Plot)




Análise: p-value = 0,9194, indica uma probabilidade de que essa variável veio de uma distribuição normal o que é comprovada pela análise gráfica.

#### 7.4 Estatística descritiva com o pacote *DescTools*

```
## -----
## n = 10
##
##      length      n      NAs    unique      Os      mean      meanCI'
##      100        100        0      = n        0  6.180589  5.941256
##      100.0%      0.0%              0.0%              6.419923
##
##      .05      .10      .25    median      .75      .90      .95
##  4.405695  4.836662  5.415575  6.058717  6.806827  7.713779  8.756472
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  5.601868  1.206185  0.195157  1.104287  1.391251  0.687871  0.368256
##
## lowest : 3.989335, 4.092172, 4.095352, 4.17679, 4.265684
## highest: 8.853064, 9.005574, 9.303441, 9.333708, 9.591203
##
## ' 95%-CI (classic)
```


**n = 10**



```
## -----
## n = 20
##
##      length      n      NAs    unique      Os      mean      meanCI'
##      100        100        0      = n        0  6.143925  5.980531
##      100.0%      0.0%              0.0%              6.307318
##
##      .05      .10      .25    median      .75      .90      .95
```


```
## 4.920595 5.231114 5.625614 5.969968 6.627485 7.402505 7.733459
##
## range      sd      vcoef      mad      IQR      skew      kurt
## 4.065305 0.823468 0.134030 0.639406 1.001871 0.630294 0.113770
##
## lowest : 4.518855, 4.6448, 4.803615, 4.868474, 4.877593
## highest: 7.751769, 7.938972, 8.024685, 8.072048, 8.584159
##
## ' 95%-CI (classic)
```

**n = 20**




```
## -----
## n = 50
##
## length      n      NAs      unique      Os      mean      meanCI'
##      100      100      0      = n      0 6.045567 5.943780
##      100.0%    0.0%      0.0%
##
## .05      .10      .25      median      .75      .90      .95
## 5.252855 5.360295 5.708535 6.056047 6.381739 6.654573 6.860707
##
## range      sd      vcoef      mad      IQR      skew      kurt
## 2.765122 0.512984 0.084853 0.511818 0.673203 0.106479 -0.017459
##
## lowest : 4.732683, 4.903193, 5.217731, 5.229889, 5.236883
## highest: 6.888885, 6.905395, 6.918689, 7.381681, 7.497805
##
## ' 95%-CI (classic)
```

n = 50




```
## -----
## n = 100
##
##      length      n      NAs    unique      Os      mean      meanCI'
##      100        100        0      = n        0  6.004604  5.931538
##      100.0%      0.0%          0.0%          6.077670
##
##      .05      .10      .25    median      .75      .90      .95
##  5.490196  5.574052  5.710250  6.014391  6.265314  6.459544  6.609217
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  1.836701  0.368236  0.061326  0.443848  0.555063  0.094753  -0.431943
##
## lowest : 5.136169, 5.175572, 5.280582, 5.38014, 5.484931
## highest: 6.632422, 6.687336, 6.726806, 6.771126, 6.97287
##
## ' 95%-CI (classic)
```

n = 100



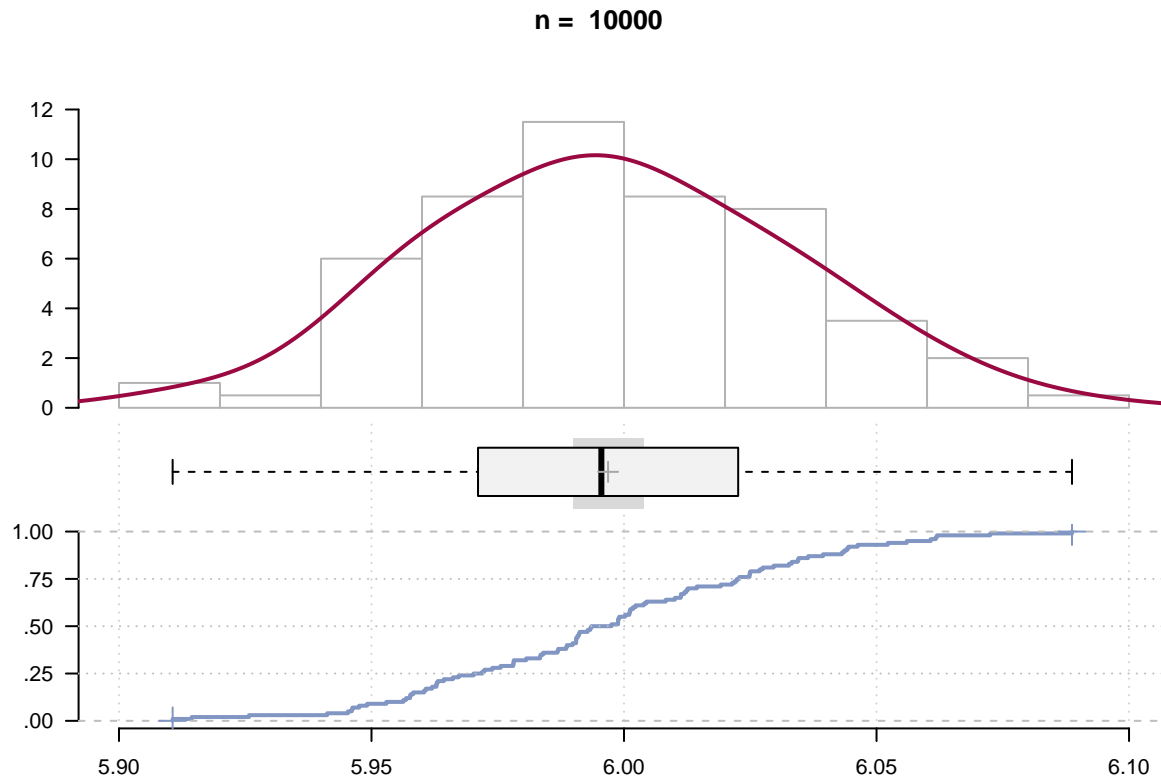
```
## -----
## n = 1000
##
##      length      n      NAs    unique      Os      mean    meanCI '
##        100       100        0      = n        0  6.002410  5.981651
##        100.0%    0.0%          0.0%          6.023170
##
##      .05      .10      .25    median      .75      .90      .95
##  5.813397  5.856454  5.943095  5.994127  6.074956  6.119676  6.190534
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  0.541629  0.104622  0.017430  0.096395  0.131861  0.149622  0.139202
##
## lowest : 5.77153, 5.772426, 5.805622, 5.811812, 5.813222
## highest: 6.194179, 6.197946, 6.228253, 6.235013, 6.313158
##
## ' 95%-CI (classic)
```

n = 1000



```
## -----
## n = 10000
##
##      length      n      NAs    unique      Os      mean      meanCI'
##      100        100        0      = n        0  5.996847  5.989829
##      100.0%     0.0%
##
##      .05      .10      .25    median      .75      .90      .95
##  5.946040  5.955968  5.971531  5.995514  6.022491  6.043640  6.056232
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  0.178080  0.035369  0.005898  0.039553  0.050960  0.074521 -0.307291
##
## lowest : 5.910626, 5.91441, 5.925746, 5.94122, 5.945336
## highest: 6.060722, 6.061737, 6.061959, 6.072504, 6.088706
##
## ' 95%-CI (classic)
```





A tabela a seguir expõem as principais métricas estatísticas da distribuição qui-quadrado geradas:

	Médias	sd	Mediana	Curtose
10	6.180589	1.206185	6.058714	0.368256
20	6.143925	0.823468	5.969968	0.113770
50	6.045567	0.512984	6.056047	-0.017459
100	6.004604	0.368236	6.014391	-0.431943
1000	6.002410	0.104622	5.994127	0.139202
10000	5.996847	0.035369	5.995514	-0.307291

## 8. TCL:Exemplo utilizando a distribuição Gama.

**8.1 Definição:** A variável aleatória  $X$  tem distribuição Gama, se sua densidade for dada por:

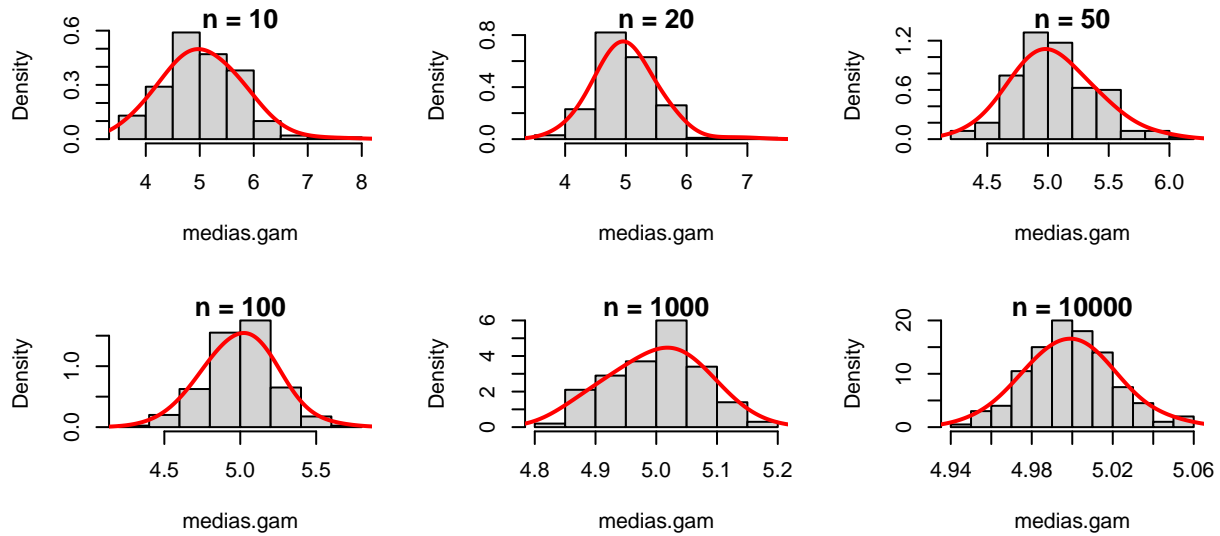
$$f(x) = \frac{\beta}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x \geq 0,$$

sendo  $\alpha$  e  $\beta$  dois parâmetros positivos e  $\Gamma(\alpha)$  sendo a função matemática Gama, definida por

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx, \quad \alpha > 0.$$

**Notação:**  $X \sim \text{Gama}(\alpha, \beta)$ .

## 8.2 TCL: Códigos no R para a elaboração dos gráficos com as simulações - Gama



Os seis histogramas nos mostram que, à medida que o tamanho  $n$  da amostra cresce, a forma do histograma se aproxima cada vez mais de uma curva normal, comprovando o *Teorema Central do Limite*.


### 8.3 Teste da Normalidade

Utilizaremos o teste de Shapiro-Wilk para verificarmos a normalidade dos dados.

```
##
## Shapiro-Wilk normality test
##
## data: medias.gam
## W = 0.99459, p-value = 0.6884
```

### 8.4 Plotando o Gráfico

#### Gráfico QQ (QQ Plot)




Análise: p-value = 0,7975, indica uma probabilidade de que essa variável veio de uma distribuição normal o que é comprovada pela análise gráfica.

## 8.5 Estatística descritiva com o pacote *DescTools*

```
## -----
## n = 10
##
##      length      n      NAs    unique      Os      mean      meanCI '
##        200      200        0      = n        0  4.991224  4.887343
##          100.0%    0.0%          0.0%          5.095104
##
##      .05      .10      .25    median      .75      .90      .95
##  3.786569  4.072046  4.477347  4.965807  5.452388  6.004163  6.283585
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  3.740320  0.744993  0.149260  0.722950  0.975041  0.110659 -0.244905
##
## lowest : 3.162623, 3.289009, 3.45462, 3.485854, 3.539154
## highest: 6.550239, 6.623321, 6.642224, 6.844316, 6.902943
##
## ' 95%-CI (classic)
```


**n = 10**



```
## -----
## n = 20
##
##      length      n      NAs    unique      Os      mean      meanCI '
##        200      200        0      = n        0  5.048975  4.972482
##          100.0%    0.0%          0.0%          5.125468
##
##      .05      .10      .25    median      .75      .90      .95
##  3.786569  4.072046  4.477347  4.965807  5.452388  6.004163  6.283585
```


```
## 4.265893 4.385271 4.652695 5.046407 5.363438 5.771639 6.051975
##
## range      sd      vcoef      mad      IQR      skew      kurt
## 3.248991 0.548580 0.108652 0.552681 0.710743 0.351826 0.132389
##
## lowest : 3.766708, 3.788259, 3.919714, 3.973337, 3.980441
## highest: 6.150516, 6.23911, 6.2544, 6.344614, 7.015699
##
## ' 95%-CI (classic)
```

**n = 20**




```
## -----
## n = 50
##
## length      n      NAs      unique      Os      mean      meanCI'
##      200      200      0      = n      0      4.972802  4.927799
##      100.0%    0.0%      0.0%      5.017805
##
## .05      .10      .25      median      .75      .90      .95
## 4.420279 4.598884 4.774845 4.989514 5.196754 5.381517 5.479187
##
## range      sd      vcoef      mad      IQR      skew      kurt
## 2.038455 0.322743 0.064902 0.313634 0.421909 -0.255996 0.330556
##
## lowest : 3.942738, 4.031695, 4.165346, 4.247356, 4.250417
## highest: 5.569642, 5.578265, 5.585192, 5.608454, 5.981193
##
## ' 95%-CI (classic)
```

n = 50




```
## -----
## n = 100
##
##      length      n      NAs    unique      Os      mean      meanCI '
##      200        200        0      = n        0  5.006404  4.976301
##      100.0%      0.0%                0.0%                5.036507
##
##      .05      .10      .25    median      .75      .90      .95
##  4.657535  4.721756  4.856038  5.014161  5.140509  5.270519  5.396649
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  1.226159  0.215888  0.043122  0.202676  0.284471  0.141008  0.153516
##
## lowest : 4.458321, 4.52, 4.540865, 4.555334, 4.600204
## highest: 5.417875, 5.458676, 5.536922, 5.665804, 5.68448
##
## ' 95%-CI (classic)
```

n = 100




```
## -----
## n = 1000
##
##      length      n      NAs  unique      Os      mean  meanCI'
##      200        200        0    = n        0  4.991335  4.982839
##      100.0%      0.0%                0.0%                4.999830
##
##      .05      .10      .25  median      .75      .90      .95
##  4.886094  4.910092  4.951842  4.994427  5.031317  5.062590  5.082352
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  0.360905  0.060927  0.012206  0.057133  0.079475  -0.169762  0.485402
##
## lowest : 4.802993, 4.807723, 4.838098, 4.867087, 4.870634
## highest: 5.123937, 5.140097, 5.142333, 5.158843, 5.163898
##
## ' 95%-CI (classic)
```

n = 1000



```
## -----
## n = 10000
##
##      length      n      NAs    unique      Os      mean    meanCI'
##      200        200        0      = n        0    4.999060  4.995676
##      100.0%      0.0%                0.0%                5.002443
##
##      .05      .10      .25    median      .75      .90      .95
##  4.959401  4.967871  4.983932  4.999221  5.014063  5.030561  5.040807
##
##      range      sd      vcoef      mad      IQR      skew      kurt
##  0.143278  0.024263  0.004854  0.022571  0.030131 -0.000684  0.160981
##
## lowest : 4.92903, 4.938155, 4.938626, 4.944822, 4.9527
## highest: 5.045579, 5.046544, 5.048387, 5.063922, 5.072308
##
## ' 95%-CI (classic)
```



A tabela a seguir expõem as principais métricas estatísticas da distribuição Gama geradas:

	Médias	sd	Mediana	Curtose
10	4.991224	0.784993	4.965807	-0.2449050
20	5.048975	0.548580	5.046407	0.1323890
50	4.972802	0.322743	4.989514	0.3305560
100	5.006404	0.215888	5.014161	0.1153516
1000	4.991335	0.060927	4.994427	0.4854020
10000	4.995676	0.024263	4.999221	0.1609810

## Conclusão

Ao utilizarmos amostras, nosso objetivo final é fazer **inferência a respeito dos reais parâmetros da população**. Para isso, usamos ferramentas como intervalos de confiança e teste de hipóteses que partem da suposição da normalidade dos dados. Desse modo, mesmo que os nossos dados sejam de uma população com distribuição desconhecida ou que não seja normalmente distribuída, ainda assim poderemos fazer tais análises uma vez que o Teorema Central do Limite é verdadeiro, (MACIEL, 2022). De forma geral, **quanto maior for a amostra, mais próxima da normal a distribuição amostral das médias será**.

## Referências

ALCOFORADO, Luciane Ferreira. Utilizando a Linguagem R: conceitos, manipulação, visualização, modelagem e elaboração de relatórios. Rio de Janeiro: Alta Books, 2021. 377 p.

MACIEL, Prof. Fernanda. Teorema Central do Limite. 2022. Disponível em: [https://blog.proffernandamaciel.com.br/teorema\\_central\\_limite/](https://blog.proffernandamaciel.com.br/teorema_central_limite/). Acesso em: 30 out. 2022.

R Core Team (2021). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. URL <https://www.R-project.org/>.



VASCONCELLOS, Klaus Leite Pinto. Fundamentos para a Estatística de Convergência de Variáveis Aleatórias. Rio de Janeiro: Sbm, 2021. 380 p. (Coleção Matemática Aplicada; 05).